



MODELE OCENY RYZYKA KREDYTOWEGO FIRM

LOGIT WOE + XGBOOST

MATEUSZ STASIAK
CEZARY POLKOWSKI



PROBLEM & CEL PROJEKTU

PROBLEM



Ręczna ocena klientów jest czasochłonna, niespójna i trudna do skalowania. Potrzebujemy sposobu, który pozwoli szybko i precyzyjnie identyfikować ryzyko.

ODPOWIEDŹ



Chcemy podejmować decyzje w sposób obiektywny i powtarzalny. Inteligentny system ratingowy umożliwia szybkie decyzje nawet przy dużej liczbie wniosków.

CELE





Stworzenie modelu PD o stabilnym działaniu. Zapewnienie interpretowalności (Logit WoE) oraz wysokiej jakości predykcji. Kalibracja PD do poziomu 4% oraz budowa ratingów i progów wspierających decyzje kredytowe.





CHARAKTERYSTYKA DANYCH

W projekcie wykorzystaliśmy rzeczywisty zbiór danych zgromadzonych ze sprawozdań finansowych firm. Zbiór początkowo zawierał ponad 200 zmiennych, obejmujących zarówno informacje finansowe (np. aktywa, zobowiązania krótkoterminowe, rentowność sprzedaży, wskaźnik płynności bieżącej), jak i zmienne opisowe. Dane podzielono losowo i stratyfikowane na 60% train, 20% validation i 20% test, aby zapewnić rzetelną ocenę jakości modeli.





MODELE

REGRESJA LOGISTYCZNA

Logit z transformacją Weight of Evidence to klasyczny model ryzyka kredytowego stosowany powszechnie w instytucjach finansowych.

Zapewnia pełną interpretowalność – dokładnie wiemy, jak każda zmienna wpływa na prawdopodobieństwo niewypłacalności firmy.

METRYKI (ZBIÓR TESTOWY):

ROC AUC: 0.7430

GINI: 0.4861

PR AUC: 0.2385

KS: 0.3917

BRIER SCORE: 0.0799

XGBOOST

XGBoost to nowoczesny model uczący się poprzez wzmacnianie błędów.

Przechwytuje złożone zależności, interakcje między cechami oraz nieliniowości, często osiągając wyższą skuteczność predykcji niż modele liniowe.

METRYKI (ZBIÓR TESTOWY):

ROC AUC: 0.7652

GINI: 0.5304

PR AUC: 0.2928


KS: 0.4267

BRIER SCORE: 0.0778




MODELE

ROC curve - Logit (WoE): train / val / test






PR curve - Logit (WoE): train / val / test





INTERPRETACJA GLOBALNA LOGIT






INTERPRETACJA GLOBALNA LOGIT



TRAIN

TEST







INTERPRETACJA LOKALNA LOGIT









INTERPRETACJA GLOBALNA XGBOOST







INTERPRETACJA LOKALNA XGBOOST







KALIBRACJA MODELI





KALIBRACJA MODELI DO 4%





RATINGI RYZYKA KREDYTOWEGO

Aby ułatwić interpretację wyników modeli, przekształciliśmy przewidywane PD w 7 klas ratingowych:

AAA, AA, A, BBB, BB, B, CCC – gdzie AAA oznacza najniższe ryzyko, a CCC najwyższe. Progi ratingów zostały wyznaczone na podstawie kwantyli PD na zbiorze treningowym, dzięki czemu klasy są stabilne i reprezentatywne.

Dla każdego ratingu obliczyliśmy statystyki: liczebność, udział defaultów oraz średnie PD.

Ratingi umożliwiają:

- łatwiejsze podejmowanie decyzji kredytowych,
- tworzenie polityk ryzyka opartych na klasach,
- porównywanie jakości portfela na przestrzeni czasu,
- komunikację z kadrą zarządczą bez konieczności używania technicznych miar modeli.



MINIMALIZACJA STRAT


Aby określić najbardziej opłacalny próg PD, zbudowaliśmy macierz kosztów, która odzwierciedla rzeczywiste konsekwencje decyzji kredytowych.

Przyjęliśmy:

- +15% – zysk na dobrze udzielonym kredycie (TP)
- –50% – strata na źle udzielonym kredycie (FP)
- –6% – koszt odrzucenia dobrego klienta (FN)
- +20% – korzyść z odrzucenia ryzykownego klienta (TN)

Dla każdego progu PD policzyliśmy oczekiwany zysk portfela.

Analiza pokazuje, że zbyt niski próg prowadzi do dużej liczby stratnych kredytów, a zbyt wysoki – do odrzucania klientów, na których bank mógłby zarobić. Najwyższy oczekiwany zysk pojawia się w przedziale PD ≈ 0.2





PODSUMOWANIE

Modele PD, mimo dobrej skuteczności, mają naturalne ograniczenia. Ich wyniki zależą od jakości danych finansowych, warunków makroekonomicznych oraz stabilności zachowania klientów. Możliwy jest drift danych, czyli sytuacja, w której profil firm lub gospodarki zmienia się na tyle, że model zaczyna działać gorzej. XGBoost jako model złożony może być trudniejszy do wyjaśnienia, a decyzje oparte wyłącznie na nim są ryzykowne. Logit jest w pełni interpretowalny, ale ma niższą skuteczność i ograniczoną zdolność do uchwycenia zależności nieliniowych.

Dlatego rekomendujemy:

- regularny monitoring jakości modeli (AUC, KS, Brier, kalibracja),
- miesięczną kontrolę stabilności danych,
- kwartalną rewizję progu decyzyjnego i jakości portfela,



DZIĘKUJEMY

za uwagę